基于非负矩阵分解的神经网络隐藏层表示分析

ReLU 与 Tanh 在 MNIST 上的比较研究

Understanding Neural Network Representations through Nonnegative Matrix Factorization:
A Comparative Study of ReLU and Tanh on MNIST

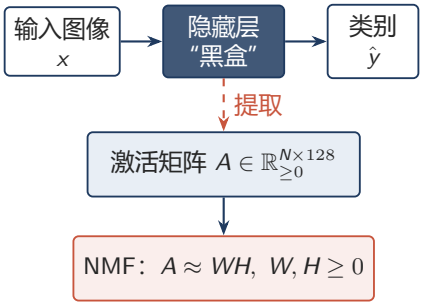
作者姓名

学校 / 学院

汇报日期

动机：ReLU 的非负输出与 NMF 的非负约束形式相近

- 深度网络常被视为“黑盒”：分类准确，但中间层表示难以直接解读
- 隐藏层激活矩阵是网络对数据的内部编码，可以当作普通矩阵分析
- ReLU 把负值截断为 0 $\Rightarrow$ 激活矩阵**非负**
- NMF 只允许非负成分相加，常被认为倾向得到“部分—整体”式表示 (Lee & Seung, 1999)



观察：分布、稀疏性、成分结构、类别关联

本项目的定位

以数值实验观察非负激活与 NMF 之间的联系；**不**主张 ReLU 网络与 NMF 在数学上等价，也**不**把更高的稀疏性等同于更强的可解释性。

四个研究问题：从激活分布到 NMF 结构

RQ1

ReLU 与 Tanh 的隐藏层激活
在**数值分布**上有何差异?

RQ2

ReLU 的非负激活是否表现出
更明显的稀疏性?

RQ3

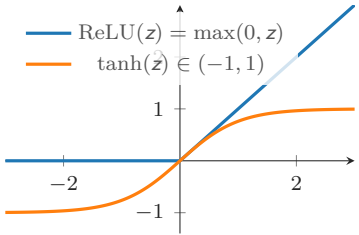
对激活矩阵做 NMF，能否得到
权重分布各不相同的 components?

RQ4

ReLU 与 Tanh 正值部分的 NMF 在
重构误差与稀疏性上有何差别?

贯穿全程的问题：这些数值现象能在多大程度上帮助我们理解网络的内部表示?

数学背景：两种激活函数与非负矩阵分解



	ReLU	Tanh
值域	$[0, \infty)$	$(-1, 1)$
精确零值	有（$z \le 0$）	仅 $z = 0$
饱和	仅负半轴	两端饱和

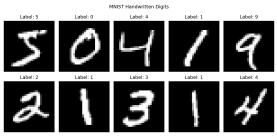
非负矩阵分解（NMF）

给定非负矩阵 $A \in \mathbb{R}^{N \times d}_{\ge 0}$ 与秩 k：

$$\min_{W \ge 0,\, H \ge 0} \ \frac{1}{2} \|A - WH\|_F^2, \qquad W \in \mathbb{R}^{N \times k},\ H \in \mathbb{R}^{k \times d}$$

- 每一行（样本）被写成 k 个非负成分的**加权叠加**：$a_i \approx \sum_{j=1}^{k} w_{ij}\, h_j$
- 因系数与成分均非负，成分之间只能相加，不能相互抵消
- 这一“加性”直觉是本项目的出发点，而**不是**结论

实验设计：仅激活函数不同的成对对照



MNIST 样本，28×28 灰度

Flatten
784

Linear
$784 \to 128$

ReLU
或 **Tanh**

Linear
$128 \to 10$

logits
10 类

隐藏层激活 A
测试集 10000×128

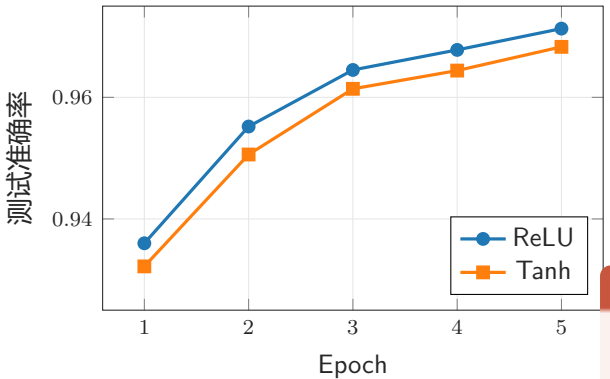
训练配置（取自 `train_models.py`）

数据	MNIST：训练 60000 / 测试 10000
预处理	`ToTensor()`，像素缩放至 $[0, 1]$
优化	Adam，学习率 10^{-3}，batch 128
损失 / 轮数	交叉熵 / 5 epochs
参数量	101,770（两模型相同）

对照设计

- 两个模型共享**同一组初始权重**（种子 42）
- 训练数据顺序相同（同一随机生成器）
- 激活在**全部测试集**上提取，标签对齐

两种网络分类性能相近：测试准确率相差 0.30 个百分点



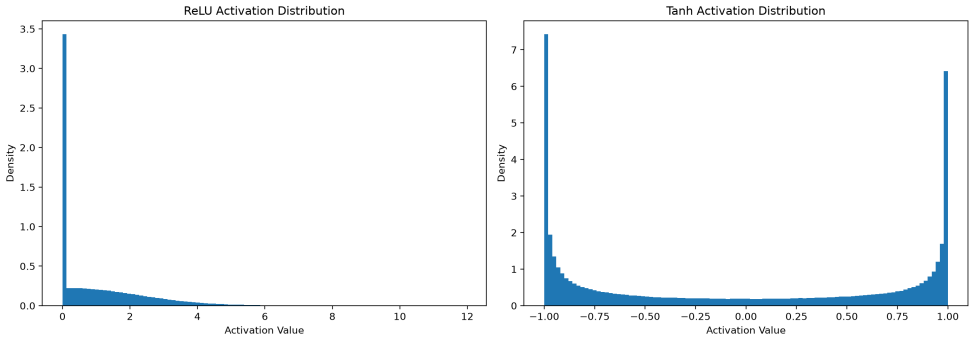
数据来源：`reports/metrics/training_results.json`

第 5 轮指标	ReLU	Tanh
测试准确率	0.9713	0.9683
测试损失	0.0955	0.1070
训练损失	0.0845	0.0944
训练时间 (s)	38.57	39.22

解读注意

每种模型**只训练了一次**，0.30 个百分点的差距不能视为统计显著；训练时间包含每轮测试评估，运行设备未记录。

原始激活：ReLU 集中于零点，Tanh 向 ± 1 两端饱和

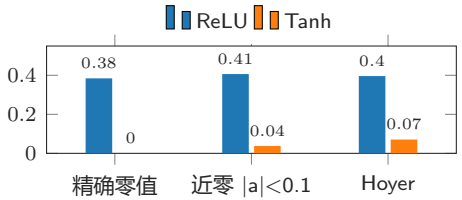


- **ReLU**：38.43% 的激活**恰好为 0**；正值部分右偏长尾，最大值 11.97
- **Tanh**：U 形分布，52.16% 为负；$|a| > 0.95$ 的比例平均为 37.7%

数据来源：`reports/activations/activation_statistics.json`；`reports/metrics/neuron_summary.json`

稀疏性：ReLU 有大量精确零值，Tanh 的幅度更“均匀”

指标（10000×128）	ReLU	Tanh
精确零值比例	0.3843	0
近零比例 $\lvert a\rvert < 0.1$	0.4063	0.0376
负值比例	0	0.5216
均值	1.0615	-0.0398
标准差	1.3272	0.8029
平均 $\lvert a\rvert$	1.0615	0.7510
平均 Hoyer（按样本）	**0.3960**	0.0707



Hoyer Sparsity (Hoyer, 2004)

$$S(x) = \frac{\sqrt{n} - \|x\|_1 / \|x\|_2}{\sqrt{n} - 1} \in [0, 1]$$

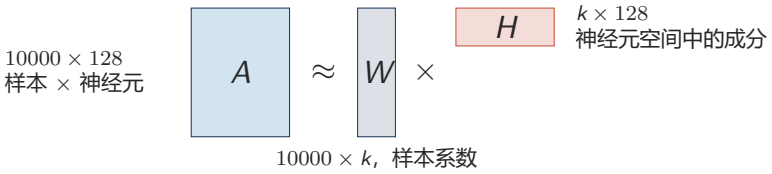
只有一个非零元时 $S = 1$；所有元素幅度相同时 $S = 0$。此处 $n = 128$，对每个样本计算后取平均（由 `activations/*.npz` 计算）。

两类指标不同

- Tanh 的 Hoyer 基于 $|a|$：衡量**幅度集中程度**，不代表存在精确零值
- Tanh 低 Hoyer 主要源于饱和：大量 $|a| \approx 1$ 使幅度趋于均匀

非负表示与 NMF：ReLU 与 Tanh 在 MNIST 上的比较

NMF 方法：ReLU 直接分解，Tanh 仅取正值部分



两组输入矩阵

- **ReLU**：A_{ReLU} 本身非负，直接分解
- **Tanh Positive**：
  $A^{+}_{\mathrm{Tanh}} = \max(A_{\mathrm{Tanh}}, 0)$

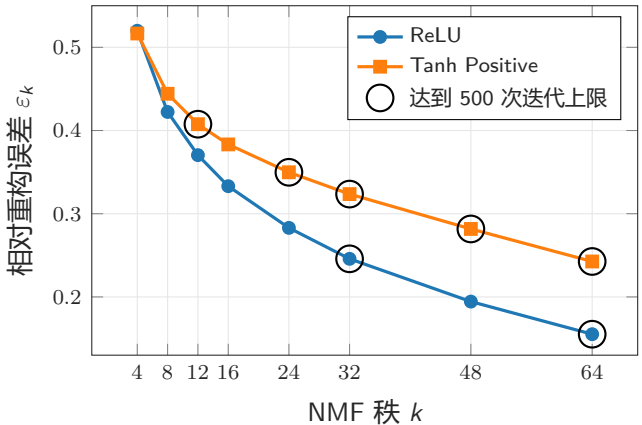
Tanh Positive 丢弃了全部负值（52.16% 的元素被置 0），并不是完整的带符号 Tanh 表示。

共同设置（scikit-learn `NMF`）

秩 k	4, 8, 12, 16, 24, 32, 48, 64
初始化	`nndsvda`
求解器	`cd`（坐标下降）
最大迭代	500
随机种子	42

相对重构误差：$\varepsilon_k = \dfrac{\|A - WH\|_F}{\|A\|_F}$

重构误差随秩下降；$k \geq 8$ 时 ReLU 误差始终更低

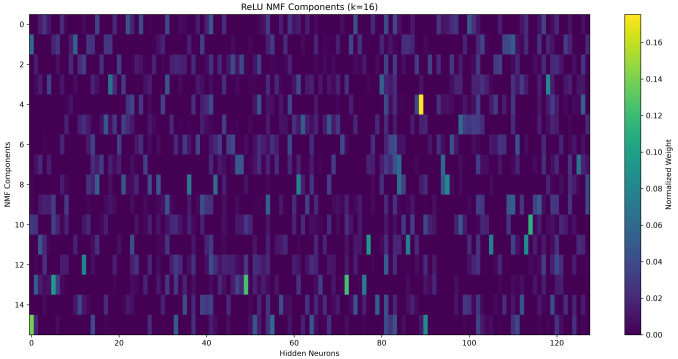


数据来源：`reports/metrics/nmf_rank_comparison.json`；`tanh_positive_nmf_results.json`

- 两条曲线均随 k 单调下降，符合“秩越大、近似越精细”的预期
- $k = 4$：Tanh Positive 略低 (0.5166 vs. 0.5199)
- $k \geq 8$：ReLU 均更低，差距随 k 扩大 ($k = 64$：0.1552 vs. 0.2426)
- 16 组配置中有 7 组迭代次数等于上限 500，可能未完全收敛

误差更低只说明低秩近似更容易，**不**等于可解释性更强。

ReLU NMF 成分（$k = 16$）：各成分集中在不同的神经元子集



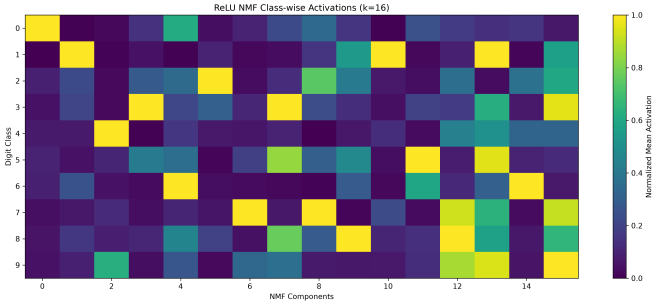
每行已按行和归一化（行和为 1），以去除成分间的尺度差异。

- **行** = 一个 NMF 成分 h_j
- **列** = 128 个隐藏神经元之一
- 每个成分只在部分神经元上有明显权重，其余接近 0
- 成分 H 的平均 Hoyer：0.5625（范围 0.47–0.69）

不是笔画图

横轴是神经元编号，**没有**二维空间排列。此图不能直接读成“横、竖、弯钩”等图像笔画。

类别关联：每个数字都有响应最强的成分，但多数成分并不专属

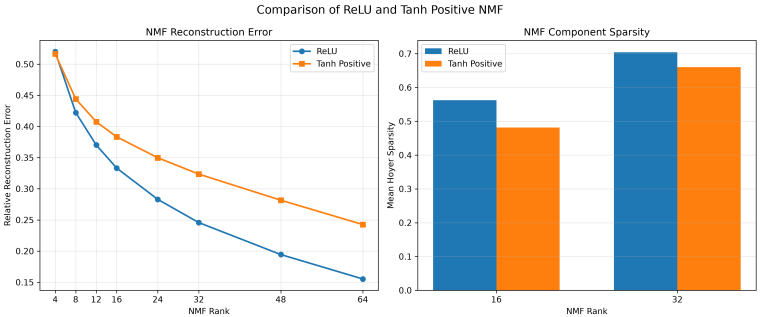


每格为该类样本在成分上的平均系数 $\bar{w}_{c,j}$，按列（成分）最大值归一化。

- 16 个成分的最强响应类别覆盖了全部 10 个数字
- 例：成分 0 主要对应数字 0，成分 2 对应数字 4
- 也有成分同时响应多个类别：成分 12 在 7、8、9 上均较强，成分 13 在 1、5、9 上均接近最大值
- 最强类与次强类的均值比：中位数 1.77，只有 7/16 个成分超过 2

这里只是统计上的类别关联，不说明某个成分“专门识别”某个数字。

综合对比：ReLU 的 NMF 误差更低、成分更集中，但优势依赖于秩



成分 H 平均 Hoyer，$k=$	4	8	12	16	24	32	48	64
ReLU	**0.367**	**0.435**	**0.508**	**0.563**	**0.635**	**0.704**	**0.783**	0.841
Tanh Positive	0.354	0.418	0.456	0.481	0.582	0.660	0.769	**0.846**

原图仅含 $k = 16, 32$；表中其余秩由已保存的 H（`reports/nmf/*.npz`）计算。$k = 64$ 时 Tanh Positive 略高。

局限性：当前证据能支持什么，不能支持什么

实验设计层面

- **Tanh Positive ≠ 完整 Tanh**：负半部分信息全部丢失
- Tanh Positive 本身有 52.16% 的零元素，比 ReLU 的 38.43% 还多，二者的输入矩阵结构不同
- 7/16 个 NMF 配置迭代次数达到上限 500；原始运行日志未保存
- 每种激活函数**只训练一次**，没有方差估计

解释层面

- 稀疏 ≠ 可解释：Hoyer 高只说明权重更集中
- 隐藏神经元没有空间排列，成分无法直接对应笔画
- 按类别关联看，Tanh Positive 成分的最强/次强比更高（$k = 16$ 中位数 3.08 vs. 1.77），说明 ReLU 并非在所有指标上占优
- 结论仅适用于单隐藏层 MLP、MNIST、当前超参数

总结：非负激活与 NMF 的联系在本实验中可观察，但不构成证明

观察到的实验事实

1. 两种网络测试准确率均约 97%，差距 0.30 个百分点（单次运行）
2. ReLU 激活有 38.43% 精确零值；Tanh 呈两端饱和的 U 形分布
3. NMF 重构误差随秩单调下降；$k \geq 8$ 时 ReLU 误差更低
4. $k \leq 48$ 时 ReLU 成分 H 的 Hoyer 更高；$k = 64$ 时二者接近
5. 成分与数字类别存在统计关联，但多数成分不专属于单一类别

后续方向

- 多随机种子重复训练，给出误差范围
- 提高迭代上限，并记录收敛状态
- 对 Tanh 采用“正负拆分” $[A^+, A^-]$ 的 NMF，保留完整信息
- 将成分映射回输入空间（如加权平均图像），检验其视觉含义

谢谢！欢迎提问