# 基于非负矩阵分解的神经网络隐藏层表示分析

## ReLU 与 Tanh 在 MNIST 上的比较研究

Understanding Neural Network Representations through Nonnegative Matrix Factorization:
A Comparative Study of ReLU and Tanh on MNIST

陈曦然　王昌祺　汪敬原

2026 年 11 月 13 日

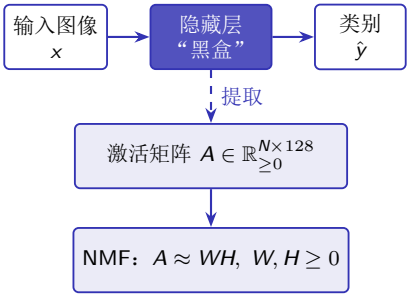
# 动机

- 深度网络常被视为“黑盒”：分类准确，但中间层表示难以直接解读
- 隐藏层激活矩阵是网络对数据的内部编码，可以当作普通矩阵分析
- ReLU 把负值截断为 0 $\Rightarrow$ 激活矩阵非负
- NMF 只允许非负成分相加，常被认为倾向得到“部分—整体”式表示 (Lee & Seung, 1999)

## 本项目的定位

以数值实验观察非负激活与 NMF 之间的联系。

# 动机

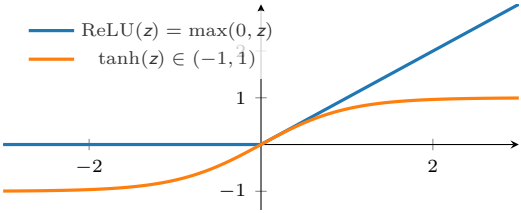



观察：分布、稀疏性、成分结构、类别关联

# 研究问题

- ReLU 与 Tanh 的隐藏层激活在数值分布上的差异
- ReLU 非负激活的稀疏性
- 对激活矩阵做 NMF 得到 components 不同的权重分布
- ReLU 与 Tanh 正值部分的 NMF 在重构误差与稀疏性的差别

# 数学背景




| | ReLU | Tanh |
|---|---|---|
| 值域 | $[0, \infty)$ | $(-1, 1)$ |
| 精确零值 | 有（$z \leq 0$） | 仅 $z = 0$ |
| 饱和 | 仅负半轴 | 两端饱和 |

# 数学背景

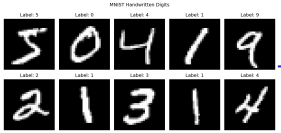
## 非负矩阵分解（NMF）

给定非负矩阵 $A \in \mathbb{R}_{\geq 0}^{N \times d}$ 与秩 $k$：

$$\min_{W \geq 0,\, H \geq 0} \ \frac{1}{2} \|A - WH\|_F^2,$$
$$W \in \mathbb{R}^{N \times k},\ H \in \mathbb{R}^{k \times d}$$

- 每一行（样本）被写成 $k$ 个非负成分的加权叠加 $a_i \approx \sum_{j=1}^{k} w_{ij}\, h_j$
- 因系数与成分均非负，成分之间只能相加，不能相互抵消
- 加性直觉是本项目的出发点

# 实验设计




MNIST 样本，$28 \times 28$ 灰度

Flatten
784

Linear
$784 \to 128$

**ReLU**
或 **Tanh**

Linear
$128 \to 10$

logits
10 类

隐藏层激活 $A$
测试集 $10000 \times 128$

# 实验设计

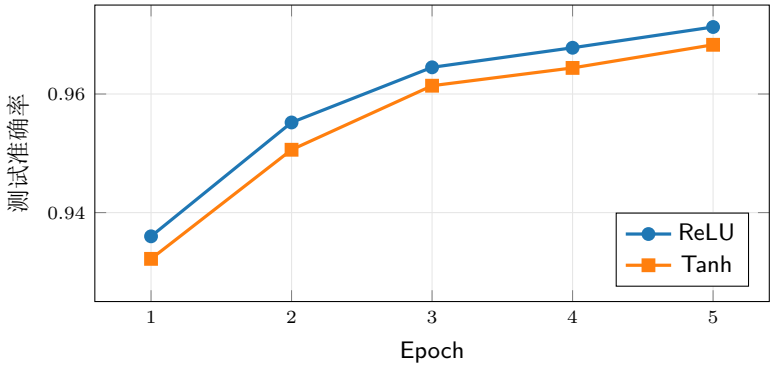
## 训练配置（取自 train_models.py）

| | |
|---|---|
| 数据 | MNIST：训练 60000 / 测试 10000 |
| 预处理 | `ToTensor()`，像素缩放至 $[0, 1]$ |
| 优化 | Adam，学习率 $10^{-3}$，batch 128 |
| 损失 / 轮数 | 交叉熵 / 5 epochs |
| 参数量 | 101,770 |

## 对照设计

- 两个模型共享同一组初始权重（种子 42）
- 训练数据顺序相同（同一随机生成器）
- 激活在全部测试集上提取，标签对齐

# 两种网络分类性能相近

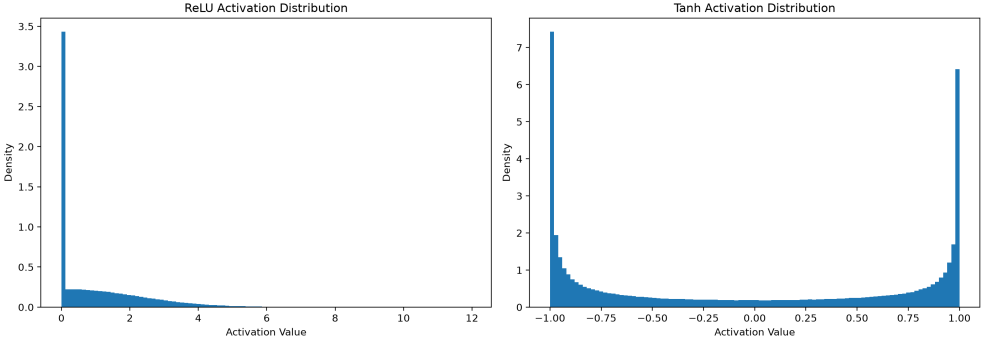



数据来源：reports/metrics/training_results.json

# 两种网络分类性能相近

| 第 5 轮指标 | ReLU | Tanh |
|---|---|---|
| 测试准确率 | 0.9713 | 0.9683 |
| 测试损失 | 0.0955 | 0.1070 |
| 训练损失 | 0.0845 | 0.0944 |
| 训练时间 (s) | 38.57 | 39.22 |

# 原始激活

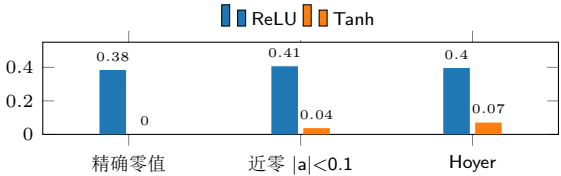



- **ReLU**：38.43% 的激活**恰好为 0**；正值部分右偏长尾，最大值 11.97
- **Tanh**：U 形分布，52.16% 为负；$|a| > 0.95$ 的比例平均为 37.7%

数据来源：`reports/activations/activation_statistics.json`; `reports/metrics/neuron_summary.json`

# 稀疏性

| 指标（$10000 \times 128$） | ReLU | Tanh |
|---|---|---|
| 精确零值比例 | 0.3843 | 0 |
| 近零比例 $\lvert a\rvert < 0.1$ | 0.4063 | 0.0376 |
| 负值比例 | 0 | 0.5216 |
| 均值 | 1.0615 | $-0.0398$ |
| 标准差 | 1.3272 | 0.8029 |
| 平均 $\lvert a\rvert$ | 1.0615 | 0.7510 |
| 平均 Hoyer（按样本） | **0.3960** | 0.0707 |



# 稀疏性

## Hoyer Sparsity (Hoyer, 2004)

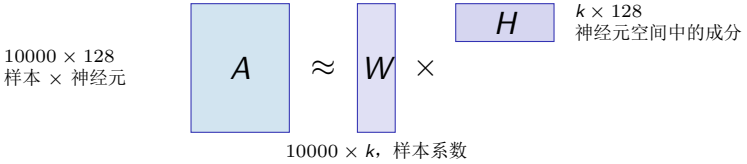
$$S(x) = \frac{\sqrt{n} - \|x\|_1 / \|x\|_2}{\sqrt{n} - 1} \in [0, 1]$$

只有一个非零元时 $S = 1$；所有元素幅度相同时 $S = 0$。此处 $n = 128$，对每个样本计算后取平均（由 `activations/*.npz` 计算）。

## 两类指标不同

- Tanh 的 Hoyer 基于 $|a|$：衡量幅度集中程度，不代表存在精确零值
- Tanh 低 Hoyer 主要源于饱和：大量 $|a| \approx 1$ 使幅度趋于均匀

# NMF 方法




## 两组输入矩阵

- **ReLU**：$A_{\mathrm{ReLU}}$ 本身非负，直接分解
- **Tanh Positive**：$A^{+}_{\mathrm{Tanh}} = \max(A_{\mathrm{Tanh}}, 0)$

Tanh Positive 丢弃了全部负值（52.16% 的元素被置 0），并不是完整的带符号 Tanh 表示。

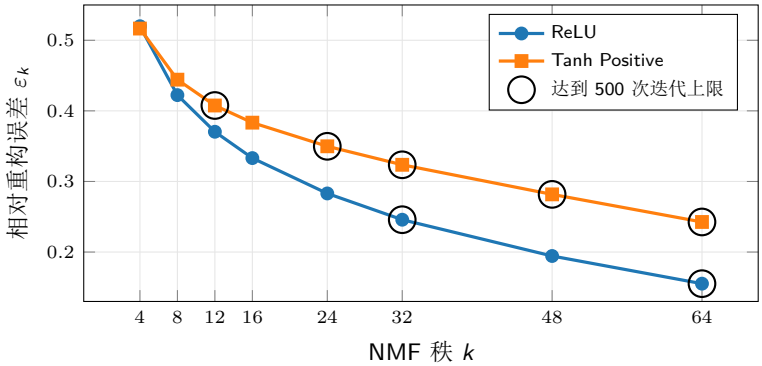
# NMF 方法

## 共同设置（scikit-learn NMF）

| | |
|---|---|
| 秩 $k$ | 4, 8, 12, 16, 24, 32, 48, 64 |
| 初始化 | `nndsvda` |
| 求解器 | `cd`（坐标下降） |
| 最大迭代 | 500 |
| 随机种子 | 42 |

相对重构误差：$\varepsilon_k = \dfrac{\|A - WH\|_F}{\|A\|_F}$

# 重构误差随秩下降

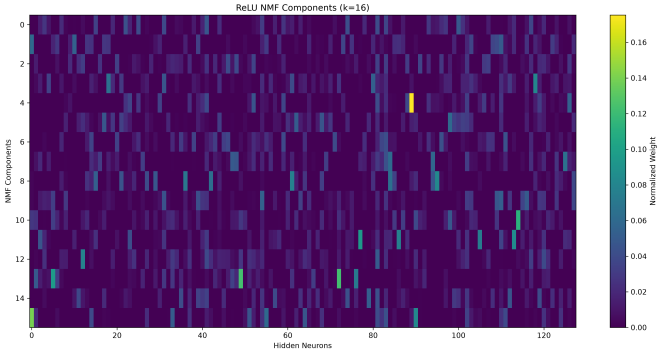



数据来源：reports/metrics/nmf_rank_comparison.json；tanh_positive_nmf_results.json

# 重构误差随秩下降

- 两条曲线均随 $k$ 单调下降，符合“秩越大、近似越精细”的预期
- $k = 4$：Tanh Positive 略低
  （0.5166 vs. 0.5199）
- $k \geq 8$：ReLU 均更低，差距随 $k$ 扩大
  （$k = 64$：0.1552 vs. 0.2426）
- 16 组配置中有 7 组迭代次数等于上限 500，可能未完全收敛

# ReLU NMF 成分（$k = 16$）




每行已按行和归一化（行和为 1），以去除成分间的尺度差异。

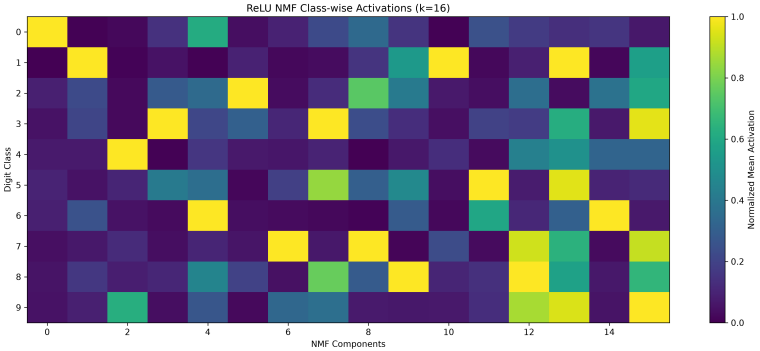
# ReLU NMF 成分（$k = 16$）

- **行** = 一个 NMF 成分 $h_j$
- **列** = 128 个隐藏神经元之一
- 每个成分只在部分神经元上有明显权重，其余接近 0
- 成分 $H$ 的平均 Hoyer：0.5625（范围 0.47–0.69）

**说明**

NMF 成分分析不能直接与笔画相对应，笔画体现在输入层

# 类别关联



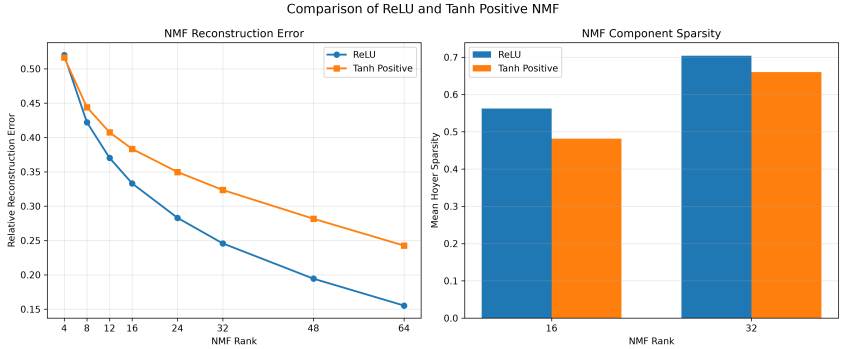

每格为该类样本在成分上的平均系数 $\bar{w}_{c,j}$，按列（成分）最大值归一化。

# 类别关联

- 16 个成分的最强响应类别覆盖了全部 10 个数字，例如成分 0 主要对应数字 0，成分 2 对应数字 4
- 有成分同时响应多个类别：成分 12 在 7、8、9 上均较强，成分 13 在 1、5、9 上均接近最大值
- 最强类与次强类的均值比：中位数 1.77，只有 7/16 个成分超过 2

这里只是统计上的类别关联，不说明某个成分“专门识别”某个数字。

# 综合对比




| 成分 $H$ 平均 Hoyer，$k=$ | 4 | 8 | 12 | 16 | 24 | 32 | 48 | 64 |
|---|---|---|---|---|---|---|---|---|
| ReLU | **0.367** | **0.435** | **0.508** | **0.563** | **0.635** | **0.704** | **0.783** | 0.841 |
| Tanh Positive | 0.354 | 0.418 | 0.456 | 0.481 | 0.582 | 0.660 | 0.769 | **0.846** |

原图仅含 $k=16,32$；表中其余秩由已保存的 $H$（`reports/nmf/*.npz`）计算，$k=64$ 时 Tanh Positive 略高。

# 局限性

## 实验设计层面

- **Tanh Positive ≠ 完整 Tanh**：负半部分信息全部丢失
- Tanh Positive 本身有 52.16% 的零元素，比 ReLU 的 38.43% 还多，二者的输入矩阵结构不同
- 7/16 个 NMF 配置迭代次数达到上限 500；原始运行日志未保存
- 每种激活函数只训练一次，没有方差估计

# 局限性

## 解释层面

- 稀疏 $\neq$ 可解释：Hoyer 高只说明权重更集中
- 隐藏神经元没有空间排列，成分无法直接对应笔画
- 按类别关联看，Tanh Positive 成分的最强/次强比更高（$k = 16$ 中位数 3.08 vs. 1.77），说明 ReLU 并非在所有指标上占优
- 结论仅适用于单隐藏层 MLP、MNIST、当前超参数

# 总结

## 观察到的实验事实

1. 两种网络测试准确率均约 97%，差距 0.30 个百分点（单次运行）
2. ReLU 激活有 38.43% 精确零值；Tanh 呈两端饱和的 U 形分布
3. NMF 重构误差随秩单调下降；$k \geq 8$ 时 ReLU 误差更低
4. $k \leq 48$ 时 ReLU 成分 $H$ 的 Hoyer 更高；$k = 64$ 时二者接近
5. 成分与数字类别存在统计关联，但多数成分不专属于单一类别

# 总结

## 后续方向

- 多随机种子重复训练，给出误差范围
- 提高迭代上限，并记录收敛状态
- 对 Tanh 采用“正负拆分”$[A^+, A^-]$ 的 NMF，保留完整信息
- 将成分映射回输入空间（如加权平均图像），检验其视觉含义

**谢谢！**